

Sucuri — Guia das coletas manuais pendentes

O que baixar, onde salvar e o que cada arquivo destrava

Projeto Sucuri

21 de julho de 2026

Contexto

Todo o pipeline automatizável do projeto já roda sozinho: despesas do Portal da Transparência (com recoleta incremental), IPCA do Banco Central e população/PIB do IBGE via sidrapy. O que resta são **fontes sem API pública utilizável**, que dependem de download ou consulta manual. Este guia detalha cada uma: passo a passo, nome exato do arquivo de destino e qual tarefa do ROADMAP.md ela destrava. As mesmas referências, em forma resumida, estão em EXTERNAL.md (itens E2–E7).

Item	Fonte	Destrava	Esforço estimado
E3	INEP (Censo da Educação Superior)	Tarefa 4.1 (custo por aluno)	~30 min
E4	SIOP (Painel do Orçamento)	Tarefa 4.2 (dotação × execução)	~30 min
E5	TCU / CGU (consulta caso a caso)	Tarefa 4.3 (validação externa)	horas, iterativo
E6	Portal (download em lote, 1 mês)	Escala das tarefas 3.1/3.7	~20 min
E7	API do Portal (reexecução)	Fechar ressalva da tarefa 3.6	~30 min de máquina

Tabela 1: Visão geral das pendências. Prioridade sugerida: E5 primeiro (única forma de calibrar a precisão dos sinais já produzidos), depois E3 e E4.

1 E3 — Matrículas por IES (INEP): destrava a tarefa 4.1

Para quê: calcular `custo_por_aluno` por instituição/ano (pago real do Conjunto B ÷ matrículas) e apontar outliers dentro de cada tipo de instituição. Sem o denominador de matrículas, o ranking de instituições fica em valor absoluto (ressalva registrada na tarefa 2.1).

Passo a passo:

1. Acesse <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-da-educacao-superior>.
2. Não é preciso baixar o microdado completo (~GB): procure a “**Sinopse Estatística da Educação Superior**” do ano desejado (arquivo `.xlsx`, dezenas de MB). A aba de interesse é a de matrículas por instituição (IES).
3. Baixe um arquivo por ano, de 2014 até o último ano publicado (o Censo tem defasagem de ~2 anos).
4. Salve como: `dados/externos/inep/matriculas_ies_<ano>.xlsx` (criar a pasta `inep/`; manter um arquivo por ano).

Verificação rápida: a sinopse deve listar as ~110 instituições federais do Conjunto B (universidades e IFs) pelo nome ou código e-MEC. **Atenção conhecida:** o nome da IES no INEP não

bate exatamente com o nome do órgão no Portal da Transparência (ex.: “Universidade Federal Fluminense” vs. “UFF”); o cruzamento da tarefa 4.1 precisará de uma tabela de correspondência — o dicionário de siglas já existente em `sucuri.utils.sigla_instituicao` é o ponto de partida.

Depois de salvar: avisar na sessão de trabalho (ou executar a tarefa 4.1 do ROADMAP), que produzirá `dados/custo_por_aluno.parquet` com a ressalva obrigatória de que o denominador não separa hospital universitário/pesquisa.

2 E4 — Dotação orçamentária (SIOP): destrava a tarefa 4.2

Para quê: comparar a dotação autorizada (LOA + créditos) com o empenhado do Conjunto A e sinalizar execução < 60% ou > 100% da dotação por programa/ação — um sinal de anomalia que a execução sozinha não revela.

Passo a passo:

1. Acesse o Painel do Orçamento: <https://www1.siop.planejamento.gov.br/paineldoorcamento/>.
2. No painel principal, aplique os filtros: **Função = 12 (Educação)** e **Subfunção = 364 (Ensino Superior)**; período **2014 até o ano atual**.
3. Configure a visualização para detalhar por **Programa** e **Ação** (mesma granularidade do Conjunto A) e inclua as medidas **Dotação Atualizada** (e, se disponível, Dotação Inicial).
4. Exporte como CSV (botão de exportação do painel).
5. Salve como: `dados/externos/siop_dotacao.csv`.

Verificação rápida: o arquivo deve ter uma linha por ano×programa×ação com códigos numéricos de programa/ação — são esses códigos (não os nomes) que casam com `codigoPrograma/codigoAcao` do Conjunto A. Se o painel só exportar nomes, reexporte incluindo as colunas de código.

Depois de salvar: tarefa 4.2 produz a tabela de divergências dotação × execução por ano.

3 E5 — Acórdãos TCU / relatórios CGU: destrava a tarefa 4.3

Para quê: a única validação externa possível dos sinais já produzidos. Sem ela, a precisão dos 176 casos priorizados é desconhecida por construção. O objetivo é calibrar (“quantos dos top casos aparecem em achados públicos?”), **não** “confirmar culpa”.

Passo a passo (iterativo, caso a caso):

1. Abra a lista de casos: `dados/casos_priorizados.csv` (ou a página “Anomalias” do painel Flask, filtrando por 3 sinais).
2. **Prioridade máxima:** “Fundação Euclides da Cunha de Apoio Institucional à UFF” — único caso atípico em três fontes independentes da Fase 3 (concentração de 86,6% dos contratos da UFF, padrão compatível com fracionamento de dispensas e convênios de R\$ 8,3 milhões). Em seguida: UFRRJ (queda 2019–2021) e UNIVASF (salto 2024–2025).
3. No TCU, pesquise cada instituição em <https://pesquisa.apps.tcu.gov.br/> (filtrar por acórdãos; restringir ao período do sinal ajuda).
4. Na CGU, pesquise relatórios de auditoria por órgão em <https://eaud.cgu.gov.br/>.
5. Para cada caso consultado, anote: instituição, ano do sinal, consulta feita, resultado (**sim** / **não** / **não pesquisável**) e link/número do acórdão ou relatório.

6. Salve as notas em: `dados/externos/tcu_cgu_notas.md` (formato livre, uma seção por caso).

Depois de salvar: tarefa 4.3 consolida a tabela caso × achado público em `relatorios/validacao_tcu.md`. Encontrar “não” em muitos casos é resultado útil (indica falso positivo ou achado ainda não auditado) — não força o sinal a “estar certo”.

4 E6 — Mapa código de órgão → Unidade Gestora: escala das tarefas 3.1 e 3.7

Para quê: os endpoints `/despesas/documentos` e `/emendas/documentos` identificam a instituição por **Unidade Gestora (UG, 6 dígitos SIAFI)**, incompatível com o `codigoOrgao` (5 dígitos) usado no resto do projeto, e a API não tem conversor. Sem esse mapa, a análise por documento só existe para o piloto (Ouro Preto) e as emendas não são atribuíveis a instituição.

Passo a passo:

1. Acesse <https://portaldatransparencia.gov.br/download-de-dados>.
2. Baixe **um único mês** (qualquer mês recente) do conjunto “Despesas — Execução” (zip com CSVs mensais).
3. Salve o zip em `dados/externos/portal_lote/despesas_execucao/` (manter o nome original do arquivo).
4. O CSV traz `codigoOrgao` e `codigoUg` na mesma linha: extraia os pares únicos e salve como `dados/externos/mapa_orgao_ug.csv` com as colunas `codigoOrgao,codigoUg,nomeOrgao` (a extração pode ser feita na sessão de trabalho — basta o zip estar salvo).

Depois de salvar: `analises/07_despesas_documentos.py` pode rodar para qualquer instituição do Conjunto B, e as emendas da tarefa 3.7 passam a ser analisáveis por instituição (hoje: só agregado nacional/UF).

5 E7 — Reexecução do CPGF do EBSEH: fecha a ressalva da tarefa 3.6

Para quê: a coleta de cartões do EBSEH recebeu HTTP 400 na página 175 — erro de servidor que o código trata como fim de paginação; os 2.610 registros salvos podem estar truncados.

Passo a passo (comando longo, rodar fora do horário comercial — limite de ~90 req/min):

```
cd ~/Library/CloudStorage/Dropbox/Repositories/seixas-solutions/sucuri
uv run python - <<'PY'
from sucuri.api import ENV_PATH_PADRAO, carregar_chave_api, criar_sessao
from sucuri.coletores.cartoes import coletar_cartoes
sessao = criar_sessao(carregar_chave_api(ENV_PATH_PADRAO))
# ano a ano para contornar o erro pontual do servidor:
total = 0
for ano in (2023, 2024, 2025):
    registros = coletar_cartoes(sessao, "26443", ano, ano)
    total += len(registros)
    print(ano, len(registros))
print("total EBSEH:", total)
PY
```

Interpretação: se o total por janelas anuais superar 2.610, a coleta original estava truncada — refazer a análise 3.6 para o EBSEH; se bater, a ressalva pode ser fechada como “sem truncamento”.

Depois de tudo coletado

Com E3–E5 em `dados/externos/`, as tarefas 4.1–4.3 do ROADMAP deixam de estar bloqueadas e podem ser executadas normalmente (cada uma registra método e resultados em `relatorios/RELATORIO.md` e na versão LaTeX, como as demais). A rotina mensal de manutenção do restante do pipeline segue automatizada — ver `EXTERNAL.md`, item X1b.

Ressalva permanente: nada nestas fontes “confirma” irregularidade; elas adicionam contexto (custo por aluno, dotação, achados públicos) para separar atipicidade explicável de indício que mereça checagem por quem tem competência para tanto.