

Sucuri

Detecção de anomalias em despesas federais com Ensino Superior
Relatório consolidado de análises, medidas e interpretações

Portal da Transparência (gov.br) — Ministério da Educação

Atualizado em 16 de julho de 2026

Resumo

Este documento é a versão em $\text{\LaTeX}$ de `relatorios/RELATORIO.md` e deve conter, ao final do projeto, todas as análises, medidas estatísticas e interpretações produzidas ao longo das fases do `ROADMAP.md`. A versão atual documenta exclusivamente a **Fase 0 — Infraestrutura do projeto**, que prepara a base de código para as análises de dados das fases seguintes; nenhuma conclusão sobre despesas é apresentada aqui ainda.

Sumário

1	Objetivo desta fase	1
2	Tarefa 0.1 — Empacotamento e ambiente	1
2.1	Estrutura criada	1
2.2	Migração de código	2
2.3	Dependências	2
2.4	Verificação dos critérios de aceite	2
3	Tarefa 0.2 — Testes unitários das funções críticas	2
3.1	Cobertura	2
3.2	Resultado da execução	3
4	Validação de não regressão	3
5	Ressalvas e decisões registradas	3
6	Estado do ROADMAP	4
	Instrução de manutenção deste relatório	4

1 Objetivo desta fase

A Fase 0 do ROADMAP não produz análises sobre as despesas em si — seu objetivo é transformar o projeto de um único script (`coletar_despesas.py`) em uma base de código reprodutível, testável e reutilizável pelas fases seguintes (qualidade de dados, deflação, detecção de anomalias). Esta seção documenta **o que foi feito**; interpretações sobre os dados de despesas começam na Fase 1/2 e serão anexadas como novas seções deste mesmo documento.

2 Tarefa 0.1 — Empacotamento e ambiente

2.1 Estrutura criada

```
pyproject.toml # projeto gerenciado por uv (PEP 621 + hatchling)
uv.lock # lockfile de dependencias
src/sucuri/
  __init__.py
  api.py # cliente da API do Portal da Transparencia
  features.py # engenharia de variaveis e construcao dos paineis A/B
  persistencia.py # salvamento de CSV/Parquet/JSON bruto e dicionario
  utils.py # brl_para_float, razao_segura, classificar_instituicao
analises/ # reservado para as fases 1-2 (vazio nesta fase)
relatorios/
  figuras/ # reservado para as fases 1-2 (vazio nesta fase)
  latex/ # este relatorio em LaTeX/PDF
tests/
  __init__.py
  test_utils.py
  test_features.py
coletar_despesas.py # CLI fino: apenas argparse + orquestracao
```

2.2 Migração de código

Toda a lógica reutilizável de `coletar_despesas.py` foi movida para o pacote `src/sucuri/`, preservando exatamente o comportamento original (mesmos parâmetros de API, mesmas fórmulas, mesmo formato de saída). A Tabela 1 resume o mapeamento.

Função/constante	Origem (script único)	Destino
<code>brl_para_float</code> , <code>_razao_segura</code> , <code>classificar_instituicao</code>	topo do script	<code>sucuri/utils.py</code> (<code>razao_segura</code> tornada pública)
<code>carregar_chave_api</code> , <code>criar_sessao</code> , <code>requisitar</code> , <code>coletar_paginado</code> , <code>coletar_intervalo</code>	seção “Coleta genérica”	<code>sucuri/api.py</code>
<code>construir_df_funcional</code> , <code>construir_df_instituicao</code> , <code>_indicadores_execucao</code> , <code>_features_serie_temporal</code> , <code>_consolidar_flags</code>	seções (A)/(B) e “Engenharia de variáveis”	<code>sucuri/features.py</code> (funções tornadas públicas)
<code>salvar_dataset</code> , <code>escrever_dicionario</code> , <code>DICIONARIO</code> , <code>resumir</code>	seção “Persistência”	<code>sucuri/persistencia.py</code>

Tabela 1: Mapeamento das funções migradas do script único para o pacote `sucuri`.

O arquivo `coletar_despesas.py` (antes `coletar_despesas_ensino_superior.py`) ficou reduzido a aproximadamente 125 linhas: apenas `argparse`, orquestração das coletas (A) e (B), e chamadas às funções do pacote. Nenhuma fórmula ou regra de negócio foi alterada durante a migração — apenas reorganizada em módulos.

2.3 Dependências

Gerenciadas por uv: `pandas`, `pyarrow`, `requests`, `python-dotenv`, `scikit-learn`, `scipy`, `matplotlib` (produção); `ruff`, `pytest` (grupo dev). O comando `uv sync -group dev` cria o ambiente virtual e resolve o lockfile em poucos segundos.

2.4 Verificação dos critérios de aceite

Critério (ROADMAP 0.1)	Resultado
<code>uv run python coletar_despesas.py -help</code> funciona	OK
<code>uv run pytest</code> roda (mesmo com 0 testes)	OK
<code>uv run ruff check .</code> sem erros	OK

3 Tarefa 0.2 — Testes unitários das funções críticas

3.1 Cobertura

Foram escritos 37 testes em dois arquivos, cobrindo exatamente as funções indicadas no ROADMAP.

`tests/test_utils.py` (23 testes)

- `brl_para_float`: formato brasileiro com separador de milhar (1.059.473.395,24), sem separador de milhar, `None`, string vazia, string só com espaços, valor já numérico (`int/float`), entrada inválida (`"abc"` → `NaN`), valor negativo.
- `razao_segura`: divisão normal e **denominador zero** → `NaN` (em vez de erro ou `inf`).
- `classificar_instituicao`: um caso por categoria (Universidade Federal, Hospitalar/EB-SERH, Instituto Federal, CEFET, CAPES, Fundo FNDE/FIES, Educação Básica, Outros/Administração), mais `None` e string vazia.

`tests/test_features.py` (14 testes)

- `indicadores_execucao`: taxas e saldos em caso normal; `empenhado == 0` → `taxas NaN sem exceção`; disparo isolado de cada flag de incoerência (`pago > empenhado`, `liquidado > empenhado`, valor negativo); ausência de falso positivo em valores coerentes.
- `features_serie_temporal`: variação anual ano a ano; disparo de `flag_salto_anual` acima de 100%; **série com desvio-padrão zero (valores constantes) não gera erro de divisão por zero** e produz `zscore NaN` em vez de indefinido; série com uma única observação; independência entre séries diferentes agrupadas no mesmo `DataFrame`.
- `consolidar_flags`: nenhuma flag ativa, uma flag ativa, flag extra (`flag_atipico_entre_pares`) considerada, valores nulos tratados como `False` na consolidação.

Os dois casos de borda explicitamente pedidos no ROADMAP — **divisão por zero** e **série com desvio-padrão zero** — estão cobertos e passam sem exceções, confirmando que as fórmulas originais (`.replace(0, pd.NA)`) já protegiam contra isso; os testes tornam essa garantia explícita e verificável automaticamente.

3.2 Resultado da execução

```
$ uv run pytest -v
===== 37 passed in 0.67s =====

$ uv run ruff check .
All checks passed!
```

Aceite (ROADMAP 0.2): **OK** `uv run pytest` verde; as funções citadas no ROADMAP (`brl_para_float`, `classificar_instituicao`, `_indicadores_execucao`, `_features_serie_temporal`, `_consolidar_flags`) têm cobertura direta.

4 Validação de não regressão

Após a migração, foi confirmado por busca no repositório que não restou nenhuma referência às funções privadas antigas (`_indicadores_execucao`, `_features_serie_temporal`, `_consolidar_flags`, `_razao_segura`) fora do pacote `sucuri`, e que os módulos migrados importam e executam corretamente. Os dados já coletados em `dados/` (dois conjuntos, 2014–2026) não foram alterados nesta fase — nenhuma coleta foi executada.

5 Ressalvas e decisões registradas

- As funções antes privadas (`_indicadores_execucao` etc.) foram tornadas públicas (sem `_`) ao mover para `sucuri/features.py`, pois passam a ser a API pública do pacote reutilizada pelas fases seguintes. Isso é uma mudança de visibilidade, não de comportamento.
- `analises/` e `relatorios/figuras/` foram criados vazios nesta fase — serão populados a partir da Fase 1/2 do ROADMAP.
- Nenhum dado foi coletado; a chave `GOVBR_API_KEY` não foi lida nem impressa durante esta fase (apenas os testes unitários, que não fazem chamadas de rede, foram executados).

6 Estado do ROADMAP

Tarefas 0.1 e 0.2 marcadas como concluídas em `ROADMAP.md`. Próxima tarefa pendente: **1.1 Relatório de qualidade dos dados** (`analises/01_qualidade.py` → `relatorios/01_qualidade.md`), que passa a ser a primeira seção deste relatório a conter interpretação de dados reais de despesas.

Instrução de manutenção deste relatório

A partir da Fase 1, toda nova tarefa do ROADMAP que gerar análise, medida estatística ou modelo deve acrescentar uma seção a este documento (e à versão Markdown em `relatorios/RELATORIO.md`) com: o que foi medido, o método usado, o resultado numérico e sua interpretação — nunca apenas o código ou o caminho do arquivo gerado. Ver `CLAUDE.md`, seção “Registro de análises e relatórios”.